

Fundamentos matemáticos de la Causalidad

Clase 3

August 31, 2026

La *paradoja* de Simpson

Simpson y covid

Se observa que la tasa de letalidad, tanto en los adultos jóvenes como en adultos mayores, es más baja en AMBA que en CABA.

Simpson's Paradox in COVID-19 Case Fatality Rates: A Mediation Analysis of Age-Related Causal Effects

Simpson y covid

Se observa que la tasa de letalidad, tanto en los adultos jóvenes como en adultos mayores, es más baja en AMBA que en CABA.

Simpson's Paradox in COVID-19 Case Fatality Rates: A Mediation Analysis of Age-Related Causal Effects

Se observa que la tasa de letalidad es más baja en AMBA que en CABA.

Simpson y covid

Se observa que la tasa de letalidad, tanto en los adultos jóvenes como en adultos mayores, es más baja en AMBA que en CABA.

Simpson's Paradox in COVID-19 Case Fatality Rates: A Mediation Analysis of Age-Related Causal Effects

Se observa que la tasa de letalidad es más baja en AMBA que en CABA.

What?

Actividad:

Sean X , T , Y variables aleatorias binarias, donde

X = Grupo etario: $X = 0/X = 1$ para adultos jóvenes/mayores)

T = $T = 1$ CABA, $T = 0$ para AMBA

Y = outcome ($Y = 1$ si se muere)

1. Expresar matemáticamente la afirmación:

Se observa que la tasa de letalidad, tanto en los adultos jóvenes como en adultos mayores, es más baja en AMBA que en CABA.

2. Expresar matemáticamente la afirmación:

Se observa que la tasa de letalidad es más baja en AMBA que en CABA.

3. Asignar valores numéricos compatibles con la situación descripta.
4. Identificar a que se debe la *extraña conclusión*.

Paradoja de Simpson y Causalidad - Actividad 2

X, T, Y binarias.

X = tamaño de la piedra ($X = 1$ si es grande)

T = tratamiento ($T = 1$ cirugía convencional, $T = 0$ para paroscópica)

Y = outcome ($Y = 1$ es éxito)

1. Expresar ingenuamente la afirmación: *treatment 1 is better for both patients with smaller and larger stones, but treatment 1 is worse for the whole population.* (Ding)
2. Expresar cuasalmente la afirmación: *treatment 1 is better for both patients with smaller and larger stones.* Demostrar que, en tal caso, treatment is better for the entire population.
3. Demostrar que *treatment 1 is better for both patients with smaller and larger stones* y se verifica el supuesto de aleatorización condicional, entonces treatment is better for the entire population.



Paradoja de Simpson

Because Simpson's paradox has been so poorly understood, some statisticians take precautions to avoid it. All too often, these methods avoid the symptom, Simpson's reversal, without doing anything about the disease, confounding. Instead of suppressing the symptoms, we should pay attention to them. Simpson's paradox alerts us to cases where at least one of the statistical trends (either in the aggregated data, the partitioned data, or both) cannot represent the causal effects.


aggregate o no aggregate: esa es la cuestión

whether you should use the aggregate or the segregated data to
determine the **true effect**.


Pinguinos: library(palmerpenguins) datos: penguins



Pinguinos: library(palmerpenguins) datos: penguins




Note: In the raw data, bill dimensions are recorded as "culmen length" and "culmen depth". The culmen is the dorsal ridge atop the bill.




¿Te suena este problema de alguna otra materia que hayas cursado?

Pinguinos: library(palmerpenguins) datos: penguins



Note: In the raw data, bill dimensions are recorded as "culmen length" and "culmen depth". The culmen is the dorsal ridge atop the bill.



¿Te suena este problema de alguna otra materia que hayas cursado?
¿Vinos?

Actividad

Armar un ejemplo donde agrupar por una variable categórica se invierta el signo de la asociación entre la variables respuesta y la predictora.

Considerar:

- Una variable de respuesta Y y una variable predictora X .
- Una variable de catogórica G .
- Una pregunta concreta que alguien podría querer responder con estos datos y se lleve el mismo *susto que nosotros con los pingüinos*.
- Generar mediante una simulacion las variables definidas y mostra los gráficos correspondientes.
- Escribir matemáticamente el mecanismo de generación de datos empleado.
- Subir a [este documento](#) el ejemplo elaborado.

Otra vez sopa

Correlación

$$\mathbb{E}(Y \mid T = 1) - \mathbb{E}(Y \mid T = 0) \neq 0$$

Correlación

$$\mathbb{E}(Y \mid T = 1) - \mathbb{E}(Y \mid T = 0) \neq 0$$

Unfortunately, statistics has fetishized this commonsense observation. It tells us that correlation is not causation, but it does not tell us what causation is

A possible definition for what causation is:

$$ATE = \mathbb{E}(Y^{(1)}) - Y^{(0)}$$

Efecto causal: $ATE \neq 0$

Aleatorización

$$Y^{(t)} \perp\!\!\!\perp T \quad \text{para } t = 0, 1$$

Lemma: Bajo aleatorización

$$\mathbb{E}(Y^{(t)}) = \mathbb{E}(Y \mid T = t)$$

Aleatorización

$$Y^{(t)} \perp\!\!\!\perp T \quad \text{para } t = 0, 1$$

Lemma: Bajo aleatorización

$$\mathbb{E}(Y^{(t)}) = \mathbb{E}(Y \mid T = t)$$

$$\mathbb{E}(Y^{(1)}) - \mathbb{E}(Y^{(0)}) = \mathbb{E}(Y \mid T = 1) - \mathbb{E}(Y \mid T = 0)$$

Aleatorización

$$Y^{(t)} \perp\!\!\!\perp T \quad \text{para } t = 0, 1$$

Lemma: Bajo aleatorización

$$\mathbb{E}(Y^{(t)}) = \mathbb{E}(Y \mid T = t)$$

$$\mathbb{E}(Y^{(1)}) - \mathbb{E}(Y^{(0)}) = \mathbb{E}(Y \mid T = 1) - \mathbb{E}(Y \mid T = 0)$$

Bajo aleatorización, correlación equivale a causalidad

Identificabilidad con aleatorización condicional

- Conditional Randomization: existe X observada tal que

$$(Y^{(t)} \perp\!\!\!\perp T) \mid X, \text{ para } t = 0, 1$$

- Lemma. Con conditional randomization y positividad tenemos identificabilidad de ATE:

$$\text{ATE} = \mathbb{E}(\mathbb{E}(Y \mid T = 1, X)) - \mathbb{E}(\mathbb{E}(Y \mid T = 0, X))$$

- Clase pasada: estimación puntual y por intervalos de ATE.

Productividad, café y turno laboral

```
prob_est_noche <- mean(datos$turno=="Noche")
prob_est_dia <- mean(datos$turno=="Da")

Y_prom_con_cafe<- mean(datos$prod[datos$turno=="Noche" & datos$
  cafe=="Toma caf"])*prob_est_noche +
mean(datos$prod[datos$turno=="Da" & datos$cafe=="Toma caf"])*prob_
  _est_dia

Y_prom_sin_cafe<- mean(datos$prod[datos$turno=="Noche" & datos$
  cafe=="No toma"])*prob_est_noche +
mean(datos$prod[datos$turno=="Da" & datos$cafe=="No toma"])*prob_
  est_dia

ATE_est <- Y_prom_con_cafe -Y_prom_sin_cafe
ATE_est
```

Productividad, café y turno laboral

```
prob_est_noche <- mean(datos$turno=="Noche")
prob_est_dia <- mean(datos$turno=="Da")

Y_prom_con_cafe<- mean(datos$prod[datos$turno=="Noche" & datos$
  cafe=="Toma caf"])*prob_est_noche +
mean(datos$prod[datos$turno=="Da" & datos$cafe=="Toma caf"])*prob_
  _est_dia

Y_prom_sin_cafe<- mean(datos$prod[datos$turno=="Noche" & datos$
  cafe=="No toma"])*prob_est_noche +
mean(datos$prod[datos$turno=="Da" & datos$cafe=="No toma"])*prob_
  est_dia

ATE_est <- Y_prom_con_cafe -Y_prom_sin_cafe
ATE_est
```

+ intervalo de confianza.

Una pregunta muy interesante...

Holaa, te pregunto ahora porq quizas me olvido hasta la proxima clase.
No hace falta que me respondas ahoraaa!

En el ejercicio que estamos haciendo de la productividad en base al cafe...
no podemos hacer dos modelos lineales que estimen la productividad en
base al cafe (y otro al cafe y el turno, o el cafe y lo que sea) y dsp hacer
un modelo Anova? y ahi ver si realmente aporta algo (positivo o
negativo) la ingesta del cafe? Es igual de valido que hacer lo del ATE? o
hay algo que no estoy siguiendo?

Una pregunta muy interesante...

Holaa, te pregunto ahora porq quizas me olvido hasta la proxima clase.
No hace falta que me respondas ahoraaa!

En el ejercicio que estamos haciendo de la productividad en base al cafe...
no podemos hacer dos modelos lineales que estimen la productividad en
base al cafe (y otro al cafe y el turno, o el cafe y lo que sea) y dsp hacer
un modelo Anova? y ahi ver si realmente aporta algo (positivo o
negativo) la ingesta del cafe? Es igual de valido que hacer lo del ATE? o
hay algo que no estoy siguiendo?

What?

Posibles ajustes

```
ajuste1 <- lm(prod ~ cafe, data = datos)
ajuste2 <- lm(prod ~ cafe + noche, data = datos)
ajuste3 <- lm(prod~cafe+noche+cafe*noche, data=datos)
```

Posibles ajustes

```
ajuste1 <- lm(prod ~ cafe, data = datos)
ajuste2 <- lm(prod ~ cafe + noche, data = datos)
ajuste3 <- lm(prod~cafe+noche+cafe*noche, data=datos)
```

¿Hay en alguno de ellos un modelo?

Estimamos ATE con y sin modelo

```
ajuste2 <- lm(prod ~ cafe + noche, data = datos)
ajuste3 <- lm(prod~cafe+noche+cafe*noche, data=datos)
```

¿Qué hacemos si X es continua?

$$r_1(X) = \mathbb{E}(Y \mid T = 1, X)$$

$$r_0(X) = \mathbb{E}(Y \mid T = 0, X)$$

$$\text{ATE} = \mathbb{E}(r_1(X)) - \mathbb{E}(r_0(X))$$

¿Qué hacemos si X es continua?

$$r_1(X) = \mathbb{E}(Y \mid T = 1, X)$$

$$r_0(X) = \mathbb{E}(Y \mid T = 0, X)$$

$$\text{ATE} = \mathbb{E}(r_1(X)) - \mathbb{E}(r_0(X))$$

- Sin modelo
- Con modelo