

Fundamentos matemáticos de la causalidad

Clase 3

La paradoja de Simpson

1. Simpson y COVID: Sean X , T , Y variables binarias, donde

X = Grupo etario: $X = 0/X = 1$ para adultos jóvenes/mayores)

T = $T = 1$ CABA, $T = 0$ para AMBA

Y = outcome ($Y = 1$ si se muere)

- (a) Expresar matemáticamente la afirmación:

Se observa que la tasa de letalidad, tanto en los adultos jóvenes como en adultos mayores, en más baja en CABA que en AMBA.

- (b) Expresar matemáticamente la afirmación:

Se observa que la tasa de letalidad en más baja en AMBA que en CABA.

- (c) Asignar valores numéricos compatibles con la situación descripta.

- (d) Identificar a que se debe la *extraña conclusión*.

2. Simpson y Causalidad: Sean X , T , Y variables binarias, donde

X = tamaño de la piedra ($X = 1$ si es grande)

T = tratamiento ($T = 1$ cirugía convencional, $T = 0$ para paroscópica)

Y = outcome ($Y = 1$ es éxito)

- (a) Expresar *ingenuamente* la afirmación: *treatment 1 is better for both patients with smaller and larger stones, but treatment 1 is worse for the whole population.* (Ding)

- (b) Expresar cuasalmente la afirmación: *treatment 1 is better for both patients with smaller and larger stones.* Demostrar que, en tal caso, treatment is better for the entire population.

- (c) Demostrar que *treatment 1 is better for both patients with smaller and larger stones* y, si se verifica el supuesto de aleatorización condicional, entonces treatment 1 is better for the entire population.

3. Leer el trabajo de Bickel, [Sex Bias in Graduate Admissions: Data from Berkeley](#). Subir a [este documento](#) un ejemplo de paradoja de Simpson, indicando si un abordaje causal permite clarificar la situación.

4. En el dataset penguins la relación entre profundidad y largo del pico es negativa si miramos todos los pingüinos juntos, pero positiva dentro de cada especie. La especie actúa como una variable que, al ignorarla, invierte el signo de la asociación. Te invitamos a pensar un ejemplo donde ocurra este mismo fenómeno, con

- Una variable de respuesta Y y una variable predictora X .
- Una variable de catagórica G .
- Una pregunta concreta que alguien podría querer responder con estos datos y se lleve el mismo *susto que nosotros con los pingüinos*.
- Generar mediante una simulacion las variables definidas y muestra los gráficos correspondientes.
- Escribir matemáticamente el mecanismo de generación de datos empleado.
- Subir a [este documento](#) el ejemplo elaborado.

¿Qué pasa si no hay identification?

Denotemos con $\mathcal{M}_k$ al simplex de dimensión k :

$$\mathcal{M}_k = \{\mathbf{x} = (x_1, \dots, x_k) : x_i \geq 0, \sum_{i=1}^k x_i = 1\}.$$

Sea T la variable dicotómica tomando valores en el conjunto $\{c, t\}$ y sean Y_t, Y_c respuestas contrafactuales tomando valores en $\{0, 1\}$. Cada posible función de probabilidad puntual para (T, Y_t, Y_c) puede identificarse con un elemento en $\mathcal{M}_8$. Para fijar notación, consideremos la siguiente tabla

$T \setminus (Y_t, Y_c)$	00	01	10	11
t	x_1	x_2	x_3	x_4
c	x_5	x_6	x_7	x_8

Table 1: Distribución conjunta entre potential outcomes y tratamiento

Consideremos la aplicación que a cada distribución conjunta $\mathbf{x}$ de las variables (Y, Y_c, Y_t) asocia la distribución de las variables observadas (T, Y) , asumiendo identificabilidad:

$$Y = Y_t I_{T=t} + Y_c I_{T=c}$$

$$L_{mg} : \mathcal{M}_8 \rightarrow \mathcal{M}_4$$

$$L_{mg}(\mathbf{x}) \sim (T, Y), \text{ si } (T, Y_c, Y_t) \sim \mathbf{x}.$$

1. Completar la tabla con la distribución de (T, Y) si $(T, Y_c, Y_t) \sim \mathbf{x}$, con $\mathbf{x}$ presentada en la Tabla .

$T \setminus Y$	0	1
t	$q_1 = \dots\dots$	$q_2 = \dots\dots$
c	$q_3 = \dots\dots$	$q_4 = \dots\dots$

2. Considerar la aplicación

$$L_{caus} : \mathcal{M}_8 \rightarrow \mathbb{R}$$

$$L_{caus}(\mathbf{x}) = \mathbb{E}(Y_t) - \mathbb{E}(Y_c), \text{ si } (T, Y_c, Y_t) \sim \mathbf{x}.$$

Obtener una formula para $L_{caus}(\mathbf{x})$ cuando $(T, Y_c, Y_t) \sim \mathbf{x}$.

$$L_{caus}(\mathbf{x}) = \dots\dots$$

3. Sea $q \in \mathcal{M}_4$ la función de probabilidad puntual para las variables observadas, dada por : Calcule

$T \setminus Y$	0	1
t	12/20	3/20
c	3/20	2/20

$$A = \min_{\mathbf{x} \in \mathcal{M}_8 : L_{mg}(\mathbf{x}) = q} L_{caus}(\mathbf{x})$$

$$B = \max_{\mathbf{x} \in \mathcal{M}_8 : L_{mg}(\mathbf{x}) = q} L_{caus}(\mathbf{x}).$$

4. Generalizar los resultados obtenidos para cualquier posible función q de probabilidad puntual para los datos observados: si $(Y, T) \sim q$ con $q \in \mathcal{M}_4$, obtener una expresión para

$$a(q) = \min_{x \in \mathcal{M}_8: L_{mg}(x)=q} L_{caus}(x)$$

$$b(q) = \max_{x \in \mathcal{M}_8: L_{mg}(x)=q} L_{caus}(x) .$$

5. Implementar computacionalmente una función llamada **cotas** que tenga por input un vector p para la distribución de los datos observados y devuelva el mínimo y máximo valor que ATE puede tomar.

Para mas información sobre el problema, se puede mirar este trabajo: [Bounds on Treatment Effects from studies with imperfect compliance](#).